Pipeline de Visión Estéreo No Calibrada

Comparación: Optical Flow vs Feature Matching (SIFT)

Formulación matemática detallada con análisis dimensional

Autores:

Carlos Andrés Canamejoy Alegría
ccanamejoy@unal.edu.co

Edward Fabian Goyeneche Velandia
egoyeneche@unal.edu.co

Juan David Muñoz Buriticá
jmunozbu@unal.edu.co

Juan Esteban Guevara Roncancio
juguevara@unal.edu.co

Laura Isabella Valero Mora
lvalerom@unal.edu.co

Samuel Esteban Reyes Nazate
sreyesn@unal.edu.co

Victor Germán Quintero Toro
viquinterot@unal.edu.co

7 de abril de 2026

Índice

1. Notación general **3**

2. Carga y preprocesamiento de imágenes **3**
2.1. Desmosaicado del sensor Bayer . . . 3
2.1.1. Desmosaicado a resolución completa . . . 3
2.1.2. Desmosaicado *half-size* (usado en el pipeline) . . . 4
2.2. Conversión a escala de grises . . . 4
2.3. Escalado a resolución de trabajo . . . 4

3. Pipeline 1: Optical Flow **5**
3.1. Detección de puntos: Shi-Tomasi . . . 5
3.1.1. Matriz de estructura . . . 5
3.1.2. Criterio de calidad de Shi-Tomasi . . . 5
3.1.3. Comparación con Harris . . . 5
3.1.4. Supresión de no-máximos . . . 6
3.2. Tracking: Lucas-Kanade piramidal . . . 6
3.2.1. Ecuación fundamental del flujo óptico . . . 6
3.2.2. Formulación de Lucas-Kanade . . . 6
3.2.3. Esquema piramidal . . . 7
3.2.4. Criterio de convergencia iterativo . . . 8
3.2.5. Filtrado de resultados . . . 8

4. Pipeline 2: Feature Matching (SIFT) **10**
4.1. Detección: espacio de escalas y DoG . . . 10
4.1.1. Espacio de escalas Gaussiano . . . 10
4.1.2. Diferencia de Gaussianas (DoG) . . . 10
4.2. Refinamiento sub-píxel . . . 10
4.2.1. Eliminación de bordes . . . 11
4.3. Asignación de orientación . . . 11
4.4. Descriptor SIFT . . . 11
4.4.1. Construcción . . . 12
4.4.2. Normalización . . . 12
4.5. Matching: distancia L_2 y ratio test de Lowe . . . 12
4.5.1. Distancia entre descriptores . . . 12
4.5.2. kNN con $k = 2$ . . . 12
4.5.3. Ratio test de Lowe . . . 13

5. Etapas compartidas **14**
5.1. Estimación de la matriz fundamental . . . 14
5.1.1. Geometría epipolar . . . 14
5.1.2. Relación con la matriz esencial . . . 14
5.1.3. Algoritmo de 8 puntos normalizado . . . 14
5.1.4. RANSAC . . . 15
5.2. Rectificación estéreo no calibrada . . . 15
5.2.1. Objetivo . . . 15
5.2.2. Método de Hartley (1999) . . . 16

5.2.3. Transformación de las imágenes 16
5.3. Mapa de disparidad: StereoSGBM 16
5.3.1. Definición de disparidad 16
5.3.2. Función de costo de matching 17
5.3.3. Agregación semi-global 17
5.3.4. Refinamiento sub-píxel 17
5.3.5. Chequeo de consistencia izquierda-derecha 18
5.3.6. Test de unicidad (`uniquenessRatio`) 18
5.3.7. Filtrado de *speckle* 18

6. Métricas de evaluación **19**
6.1. Métricas de correspondencia 19
6.2. Métricas de disparidad 19
6.2.1. Fracción de disparidad válida 19
6.2.2. Disparidad media 19

7. Visualización **19**
7.1. Normalización del mapa de disparidad 19
7.2. Visualización de correspondencias 20

8. Implementación práctica del Pipeline de correspondencias **20**
8.1. Matching exhaustivo (Brute-Force) 20
8.2. Filtrado mediante ratio test 20
8.3. Selección espacial uniforme de keypoints 21
8.4. Construcción de correspondencias finales 21
8.5. Filtrado robusto mediante RANSAC 21
8.6. Región válida tras rectificación 22
8.7. Cálculo del mapa de disparidad 22

1. Notación general

A lo largo de este documento se emplea la siguiente notación:

- $I : \Omega \subset \mathbb{R}^2 \to \mathbb{R}$ denota una imagen en escala de grises definida sobre un dominio rectangular $\Omega = \{0, \ldots, W-1\} \times \{0, \ldots, H-1\}$.
- I_1, I_2 denotan las imágenes izquierda y derecha del par estéreo, ambas de dimensiones $H \times W$.
- Los puntos en coordenadas homogéneas se escriben $\tilde{\mathbf{x}} = (x, y, 1)^\top \in \mathbb{R}^3$; en coordenadas cartesianas, $\mathbf{x} = (x, y)^\top \in \mathbb{R}^2$.
- Las matrices se denotan en negrita mayúscula ($\mathbf{F}$, $\mathbf{H}$, $\mathbf{M}$).
- $\|\cdot\|_2$ denota la norma euclidiana.

2. Carga y preprocesamiento de imágenes

2.1. Desmosaicado del sensor Bayer

El sensor de la cámara captura una imagen RAW $I_{\text{raw}} \in \mathbb{R}^{H_s \times W_s}$ donde cada píxel registra un único canal cromático según el patrón de Bayer. El arreglo del filtro de color (CFA) se modela como:

$$I_{\text{raw}}(i,j) = \begin{cases} I_G(i,j) & \text{si } (i+j) \text{ mód } 2 = 0 \\ I_R(i,j) & \text{si } i \text{ mód } 2 = 0 \text{ y } j \text{ mód } 2 = 1 \\ I_B(i,j) & \text{si } i \text{ mód } 2 = 1 \text{ y } j \text{ mód } 2 = 0 \end{cases} \tag{1}$$

donde $H_s \times W_s$ es la resolución nativa del sensor (típicamente 4000–8000 píxeles por lado).

2.1.1. Desmosaicado a resolución completa

El desmosaicado estándar interpola los dos canales faltantes en cada posición. Para el canal rojo en un píxel verde, por ejemplo:

$$\hat{I}_R(i,j) = \frac{1}{|\mathcal{N}_R(i,j)|} \sum_{(m,n) \in \mathcal{N}_R(i,j)} I_{\text{raw}}(m,n) \tag{2}$$

donde $\mathcal{N}_R(i,j)$ es el conjunto de vecinos que capturan rojo. Algoritmos más sofisticados (adaptativos, basados en gradientes) minimizan artefactos en bordes.

Dimensiones: Entrada: $I_{\text{raw}} \in \mathbb{R}^{H_s \times W_s \times 1}$. Salida a resolución completa: $I_{\text{RGB}} \in \mathbb{R}^{H_s \times W_s \times 3}$.

2.1.2. Desmosaicado *half-size* (usado en el pipeline)

Con la opción `half_size=True`, cada bloque de 2×2 del patrón Bayer (que contiene exactamente 1R, 2G, 1B) se colapsa en un único píxel RGB:

$$I_{\text{half}}(i,j) = \begin{pmatrix} I_{\text{raw}}(2i, 2j+1) \\ \dfrac{I_{\text{raw}}(2i,2j) + I_{\text{raw}}(2i+1,2j+1)}{2} \\ I_{\text{raw}}(2i+1, 2j) \end{pmatrix} \quad \text{para } i \in \left\{0, \ldots, \frac{H_s}{2} - 1\right\},\ j \in \left\{0, \ldots, \frac{W_s}{2} - 1\right\} \tag{3}$$

Dimensiones: Entrada: $I_{\text{raw}} \in \mathbb{R}^{H_s \times W_s}$. Salida: $I_{\text{half}} \in \mathbb{R}^{H_s/2 \times W_s/2 \times 3}$. Reducción a $\frac{1}{4}$ de los píxeles originales.

2.2. Conversión a escala de grises

La imagen RGB se convierte a escala de grises mediante la ponderación estándar ITU-R BT.601:

$$I_{\text{gray}}(i,j) = 0{,}299\, R(i,j) + 0{,}587\, G(i,j) + 0{,}114\, B(i,j) \tag{4}$$

Dimensiones: Entrada: $I_{\text{half}} \in \mathbb{R}^{H_s/2 \times W_s/2 \times 3}$. Salida: $I_{\text{gray}} \in \mathbb{R}^{H_s/2 \times W_s/2}$.

2.3. Escalado a resolución de trabajo

Sea $D = \text{máx}(W, H)$ la dimensión mayor de I_{gray}. Si $D > 1024$, se aplica un factor de escala:

$$s = \frac{1024}{D}, \qquad W' = \lfloor s \cdot W \rfloor, \qquad H' = \lfloor s \cdot H \rfloor \tag{5}$$

El reescalado se realiza mediante interpolación bilineal. Sea (x', y') una coordenada en la imagen destino; su valor se obtiene de:

$$I'(x', y') = \sum_{m=0}^{1} \sum_{n=0}^{1} I(\lfloor x \rfloor + m, \lfloor y \rfloor + n) \cdot (1 - |x - \lfloor x \rfloor - m|) \cdot (1 - |y - \lfloor y \rfloor - n|) \tag{6}$$

donde $(x, y) = (x'/s,\ y'/s)$ es la coordenada mapeada en la imagen original.

Dimensiones: Entrada: $I_{\text{gray}} \in \mathbb{R}^{H \times W}$. Salida: $I \in \mathbb{R}^{H' \times W'}$ con $\text{máx}(H', W') \leq 1024$.

Las imágenes finales de trabajo son $I_1, I_2 \in \mathbb{R}^{H' \times W'}$, ambas en escala de grises, con valores en $[0, 255]$.

3. Pipeline 1: Optical Flow

3.1. Detección de puntos: Shi-Tomasi

3.1.1. Matriz de estructura

Para cada píxel (x, y), se calcula la **matriz de estructura** (o tensor de estructura) $\mathbf{M}$ sobre una ventana W de tamaño $B \times B$ (con $B = 7$):

$$\mathbf{M}(x, y) = \sum_{(u,v)\in W} w(u, v) \begin{pmatrix} I_x^2(u, v) & I_x(u, v)\, I_y(u, v) \\ I_x(u, v)\, I_y(u, v) & I_y^2(u, v) \end{pmatrix} \tag{7}$$

donde $I_x = \frac{\partial I}{\partial x}$ e $I_y = \frac{\partial I}{\partial y}$ son los gradientes espaciales calculados mediante el operador de Sobel, y $w(u, v)$ es una ventana de ponderación (uniforme o Gaussiana).

Dimensiones: $\mathbf{M}(x, y) \in \mathbb{R}^{2\times 2}$ simétrica semidefinida positiva, calculada para cada píxel de $I_1 \in \mathbb{R}^{H'\times W'}$.

3.1.2. Criterio de calidad de Shi-Tomasi

Los eigenvalores de $\mathbf{M}$ se obtienen de:

$$\lambda_{1,2} = \frac{\mathrm{Tr}(\mathbf{M}) \pm \sqrt{\mathrm{Tr}(\mathbf{M})^2 - 4\,\mathrm{Det}(\mathbf{M})}}{2} \tag{8}$$

donde $\mathrm{Tr}(\mathbf{M}) = M_{11} + M_{22}$ y $\mathrm{Det}(\mathbf{M}) = M_{11}M_{22} - M_{12}^2$.
El criterio de Shi-Tomasi define la calidad como:

$$R(x, y) = \text{mín}\big(\lambda_1(x, y),\ \lambda_2(x, y)\big) \tag{9}$$

Un punto es aceptado como esquina si:

$$R(x, y) \geq q \cdot R_{\text{máx}} \tag{10}$$

donde $q = 0{,}01$ es el `qualityLevel` y $R_{\text{máx}} = \text{máx}_{(x,y)}\, R(x, y)$.

3.1.3. Comparación con Harris

El detector de Harris usa un criterio diferente:

$$R_{\text{Harris}} = \mathrm{Det}(\mathbf{M}) - k \cdot \mathrm{Tr}(\mathbf{M})^2 = \lambda_1\lambda_2 - k(\lambda_1 + \lambda_2)^2 \tag{11}$$

con $k \in [0{,}04, 0{,}06]$. Shi-Tomasi es más estable porque $\text{mín}(\lambda_1, \lambda_2)$ es un criterio más estricto: rechaza puntos donde un eigenvalor es alto pero el otro es bajo (bordes), mientras que Harris puede aceptarlos si el producto $\lambda_1\lambda_2$ es suficientemente grande.

3.1.4. Supresión de no-máximos

Tras ordenar los candidatos por R descendente, se aplica supresión de no-máximos con radio $d_{\text{mín}} = 7$ píxeles: un punto se acepta solo si ningún punto previamente aceptado está a distancia menor que $d_{\text{mín}}$:

$$\forall\, \mathbf{p}_j \text{ ya aceptado}: \quad \|\mathbf{p}_i - \mathbf{p}_j\|_2 \geq d_{\text{mín}} \tag{12}$$

Se retienen como máximo $N_{\text{máx}} = 3000$ puntos.

Dimensiones: Salida: conjunto $\mathcal{P}_1 = \{\mathbf{p}_1^{(1)}, \ldots, \mathbf{p}_K^{(1)}\} \subset \mathbb{R}^2$ con $K \leq 3000$. Cada $\mathbf{p}_k^{(1)} = (x_k, y_k)^\top$.

3.2. Tracking: Lucas-Kanade piramidal

3.2.1. Ecuación fundamental del flujo óptico

Bajo la hipótesis de **constancia de brillo**, la intensidad de un punto se conserva:

$$I(x, y, t) = I(x + \delta x,\ y + \delta y,\ t + \delta t) \tag{13}$$

Expandiendo en serie de Taylor de primer orden y dividiendo por δt:

$$\frac{\partial I}{\partial x}\frac{dx}{dt} + \frac{\partial I}{\partial y}\frac{dy}{dt} + \frac{\partial I}{\partial t} = 0 \tag{14}$$

En forma vectorial compacta:

$$\nabla I^\top \mathbf{v} + I_t = 0 \tag{15}$$

donde $\nabla I = (I_x, I_y)^\top$ es el gradiente espacial y $\mathbf{v} = (u, v)^\top$ es el vector de flujo óptico a estimar. Esta es una ecuación con dos incógnitas — el **problema de apertura**.

3.2.2. Formulación de Lucas-Kanade

Lucas-Kanade resuelve el problema de apertura asumiendo que todos los píxeles dentro de una ventana W de tamaño $w \times w$ (con $w = 21$) comparten el mismo desplazamiento $\mathbf{v}$. Esto genera un sistema sobredeterminado de $w^2 = 441$ ecuaciones con 2 incógnitas:

$$\mathbf{A}\mathbf{v} = \mathbf{b} \tag{16}$$

donde:

$$\mathbf{A} = \begin{pmatrix} I_x(\mathbf{p}_1) & I_y(\mathbf{p}_1) \\ I_x(\mathbf{p}_2) & I_y(\mathbf{p}_2) \\ \vdots & \vdots \\ I_x(\mathbf{p}_n) & I_y(\mathbf{p}_n) \end{pmatrix} \in \mathbb{R}^{n\times 2}, \qquad \mathbf{b} = -\begin{pmatrix} I_t(\mathbf{p}_1) \\ I_t(\mathbf{p}_2) \\ \vdots \\ I_t(\mathbf{p}_n) \end{pmatrix} \in \mathbb{R}^n \tag{17}$$

con $n = w^2$ píxeles en la ventana.
La solución por mínimos cuadrados ponderados es:

$$\mathbf{v} = (\mathbf{A}^\top \mathbf{W}\mathbf{A})^{-1}\mathbf{A}^\top \mathbf{W}\mathbf{b} \tag{18}$$

donde $\mathbf{W} = \operatorname{diag}\big(w(\mathbf{p}_1), \ldots, w(\mathbf{p}_n)\big)$ es una matriz diagonal de pesos (típicamente Gaussiana).

Expandiendo $\mathbf{A}^\top\mathbf{W}\mathbf{A}$:

$$\mathbf{A}^\top\mathbf{W}\mathbf{A} = \mathbf{M} = \sum_i w_i \begin{pmatrix} I_x^2(\mathbf{p}_i) & I_x(\mathbf{p}_i)I_y(\mathbf{p}_i) \\ I_x(\mathbf{p}_i)I_y(\mathbf{p}_i) & I_y^2(\mathbf{p}_i) \end{pmatrix} \tag{19}$$

y el vector del lado derecho:

$$\mathbf{A}^\top\mathbf{W}\mathbf{b} = -\sum_i w_i \begin{pmatrix} I_x(\mathbf{p}_i)I_t(\mathbf{p}_i) \\ I_y(\mathbf{p}_i)I_t(\mathbf{p}_i) \end{pmatrix} \tag{20}$$

La solución tiene forma cerrada:

$$\begin{pmatrix} u \\ v \end{pmatrix} = \begin{pmatrix} \sum w_i I_x^2 & \sum w_i I_x I_y \\ \sum w_i I_x I_y & \sum w_i I_y^2 \end{pmatrix}^{-1} \begin{pmatrix} -\sum w_i I_x I_t \\ -\sum w_i I_y I_t \end{pmatrix} \tag{21}$$

La inversión es estable si y solo si $\mathbf{M}$ tiene ambos eigenvalores suficientemente grandes — exactamente la condición de Shi-Tomasi. Esto es lo que hace que los puntos detectados en la etapa anterior sean especialmente aptos para el tracking.

3.2.3. Esquema piramidal

Se construye una pirámide Gaussiana con $L+1$ niveles ($L = 3$, `maxLevel`):

$$I^{(\ell)} = \operatorname{downsample}\big(G_\sigma * I^{(\ell-1)}\big), \quad \ell = 1, \ldots, L \tag{22}$$

donde G_σ es un filtro Gaussiano de suavizado y el *downsample* reduce cada dimensión por un factor de 2:

$$I^{(\ell)}(i,j) = (G_\sigma * I^{(\ell-1)})(2i, 2j) \tag{23}$$

Dimensiones: Pirámide para $I \in \mathbb{R}^{H' \times W'}$: nivel $0 = H' \times W'$, nivel $1 = \lfloor H'/2 \rfloor \times \lfloor W'/2 \rfloor$, nivel $2 = \lfloor H'/4 \rfloor \times \lfloor W'/4 \rfloor$, nivel $3 = \lfloor H'/8 \rfloor \times \lfloor W'/8 \rfloor$.

El algoritmo procede de arriba a abajo:

Paso 1: En el nivel $\ell = L$ (más grueso), inicializar el flujo en $\mathbf{v}^{(L)} = \mathbf{0}$.

Paso 2: Para cada nivel $\ell = L, L-1, \ldots, 0$:

(a) Calcular el flujo incremental $\delta\mathbf{v}^{(\ell)}$ resolviendo Lucas-Kanade en $I_1^{(\ell)}$ e $I_2^{(\ell)}$ con inicialización $\mathbf{v}^{(\ell)}$.

(b) Propagar al nivel inferior: $\mathbf{v}^{(\ell-1)} = 2\left(\mathbf{v}^{(\ell)} + \delta\mathbf{v}^{(\ell)}\right)$.

Paso 3: El flujo final es $\mathbf{v}^{(0)}$.

El desplazamiento máximo resoluble es aproximadamente $w \cdot 2^L = 21 \cdot 8 = 168$ píxeles.

3.2.4. Criterio de convergencia iterativo

En cada nivel, Lucas-Kanade se resuelve iterativamente (Newton-Raphson). Sea $\mathbf{v}^{(k)}$ la estimación en la iteración k:

$$\mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} + \delta\mathbf{v}^{(k)} \tag{24}$$

donde $\delta\mathbf{v}^{(k)}$ se obtiene resolviendo el sistema de Lucas-Kanade con la imagen I_2 desplazada por $\mathbf{v}^{(k)}$. Se detiene cuando:

$$\|\delta\mathbf{v}^{(k)}\|_2 < \epsilon = 0{,}01 \quad \text{o} \quad k \geq k_{\text{máx}} = 30 \tag{25}$$

3.2.5. Filtrado de resultados

Para cada punto $\mathbf{p}_i^{(1)}$, el tracker retorna un indicador de estado $s_i \in \{0, 1\}$. Un punto se marca como fallido ($s_i = 0$) si el sistema de Lucas-Kanade es singular, si el punto se sale de los límites de la imagen, o si el error residual es excesivo.

Dimensiones: Entrada: $\mathcal{P}_1 = \{\mathbf{p}_k^{(1)}\}_{k=1}^{K}$ con $K \leq 3000$, cada $\mathbf{p}_k^{(1)} \in \mathbb{R}^2$. Salida: pares correspondientes $\{(\mathbf{p}_k^{(1)}, \mathbf{p}_k^{(2)})\}_{k \in S}$ donde $S = \{k : s_k = 1\}$, con $|S| \geq 8$.

Cuadro 1: Hiperparámetros del Pipeline 1: Optical Flow

Etapa	**Parámetro**	**Valor**	**Descripción**
Shi-Tomasi (`goodFeaturesToTrack`)	`maxCorners`	3000	Número máximo de esquinas a detectar en I_1.
	`qualityLevel`	0.01	Umbral relativo: $R \geq q \cdot R_{\text{máx}}$.
	`minDistance`	7 px	Radio de supresión de no-máximos entre puntos aceptados.
	`blockSize`	7×7	Ventana para el cálculo de la matriz de estructura $\mathbf{M}$.
Lucas-Kanade (`calcOpticalFlowPyrLK`)	`winSize`	21×21	Ventana de búsqueda local. Define el número de ecuaciones del sistema sobredeterminado (441).
	`maxLevel`	3	Niveles de pirámide Gaussiana. Desplazamiento máximo resoluble $\approx w \cdot 2^L = 168$ px.
	`criteria`	$\epsilon = 0{,}01,\ \ k_{\text{máx}} = 30$	Convergencia: se detiene cuando $\lVert\delta\mathbf{v}\rVert_2 < \epsilon$ o tras $k_{\text{máx}}$ iteraciones.
Matriz fundamental (`findFundamentalMat`)	`method`	FM_RANSAC	Estimación robusta con muestreo aleatorio de 8 puntos.
	`ransacReproj- Threshold`	1.0 px	Distancia máxima punto-a-línea epipolar para clasificar un inlier.
	`confidence`	0.99	Probabilidad de obtener al menos una muestra libre de outliers. Determina N_{iter}.
Disparidad (`StereoSGBM`)	`minDisparity`	0	Disparidad mínima buscada.
	`numDisparities`	128	Rango de búsqueda: $d \in [0, 128)$. Debe ser múltiplo de 16.
	`blockSize`	5×5	Bloque de matching local.
	`P1`	200	Penalización por $\lvert d_p - d_q\rvert = 1$ (suavidad). $P_1 = 8\,b^2$.
	`P2`	800	Penalización por $\lvert d_p - d_q\rvert > 1$ (discontinuidades). $P_2 = 32\,b^2$.
	`disp12MaxDiff`	1 px	Tolerancia del chequeo de consistencia izquierda-derecha.
	`uniquenessRatio`	10 %	El mejor costo debe superar al segundo por al menos este margen.
	`speckleWindowSize`	100 px	Tamaño mínimo de regiones conexas de disparidad válida.
	`speckleRange`	32	Variación máxima de disparidad dentro de una región conexa.

4. Pipeline 2: Feature Matching (SIFT)

4.1. Detección: espacio de escalas y DoG

4.1.1. Espacio de escalas Gaussiano

El espacio de escalas se construye convolucionando la imagen con un kernel Gaussiano de varianza creciente:

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \tag{26}$$

donde:

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \tag{27}$$

El espacio se organiza en **octavas**. Cada octava contiene $s + 3$ niveles de suavizado ($s = 3$ por defecto), con escalas:

$$\sigma_j = \sigma_0 \cdot k^j, \quad k = 2^{1/s}, \quad j = 0, 1, \ldots, s + 2 \tag{28}$$

donde $\sigma_0 = 1{,}6$ es la escala base. Al pasar a la siguiente octava, la imagen se submuestrea por 2 y las escalas se duplican.

Dimensiones: Octava o: imagen de tamaño $\lfloor H'/2^o \rfloor \times \lfloor W'/2^o \rfloor$, con $s+3$ niveles. Número total de octavas: $O = \lfloor \log_2(\text{mín}(H', W')) \rfloor - 3$.

4.1.2. Diferencia de Gaussianas (DoG)

Los keypoints se detectan como extremos en las Diferencias de Gaussianas:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \approx (k - 1)\, \sigma^2\, \nabla^2 L \tag{29}$$

Esta es una aproximación eficiente del Laplaciano normalizado por escala $\sigma^2 \nabla^2 L$ (Lindeberg).

Un punto (x_0, y_0, σ_0) es candidato a keypoint si es un extremo local (máximo o mínimo) comparado con sus 26 vecinos: 8 en la misma escala + 9 en la escala superior + 9 en la escala inferior.

Dimensiones: Cada octava produce $s+2$ imágenes DoG, de las cuales s son buscables (las 2 extremas no tienen vecinos completos en escala).

4.2. Refinamiento sub-píxel

Los candidatos se refinan mediante interpolación cuadrática. Sea $D(\mathbf{x})$ la función DoG; expandiendo en Taylor alrededor del candidato $\mathbf{x}_0 = (x, y, \sigma)^\top$:

$$D(\mathbf{x}_0 + \delta\mathbf{x}) \approx D(\mathbf{x}_0) + \frac{\partial D}{\partial \mathbf{x}}^\top \delta\mathbf{x} + \frac{1}{2}\, \delta\mathbf{x}^\top \frac{\partial^2 D}{\partial \mathbf{x}^2} \delta\mathbf{x} \tag{30}$$

El offset óptimo se obtiene igualando el gradiente a cero:

$$\hat{\delta\mathbf{x}} = -\left(\frac{\partial^2 D}{\partial \mathbf{x}^2}\right)^{-1} \frac{\partial D}{\partial \mathbf{x}} \tag{31}$$

Dimensiones: $\hat{\delta\mathbf{x}} \in \mathbb{R}^3$ (offsets sub-píxel en x, y y σ). Las derivadas se computan con diferencias finitas en la escala discreta.

El valor de contraste interpolado es:

$$D(\hat{\mathbf{x}}) = D(\mathbf{x}_0) + \frac{1}{2}\frac{\partial D}{\partial \mathbf{x}}^\top \hat{\delta\mathbf{x}} \tag{32}$$

Se descartan puntos con $|D(\hat{\mathbf{x}})| < 0{,}03$ (bajo contraste).

4.2.1. Eliminación de bordes

Los puntos sobre bordes tienen un eigenvalor dominante en la Hessiana 2D:

$$\mathbf{H}_{2D} = \begin{pmatrix} D_{xx} & D_{xy} \\ D_{xy} & D_{yy} \end{pmatrix} \tag{33}$$

Sea $r = \lambda_{\text{máx}}/\lambda_{\text{mín}}$ la razón de eigenvalores. Se descarta el punto si:

$$\frac{\mathrm{Tr}(\mathbf{H}_{2D})^2}{\mathrm{Det}(\mathbf{H}_{2D})} = \frac{(\lambda_{\text{máx}} + \lambda_{\text{mín}})^2}{\lambda_{\text{máx}} \cdot \lambda_{\text{mín}}} > \frac{(r_{\text{th}} + 1)^2}{r_{\text{th}}} \tag{34}$$

con $r_{\text{th}} = 10$, lo que da un umbral de $\frac{121}{10} = 12{,}1$. Este test es computacionalmente eficiente porque evita calcular los eigenvalores explícitamente.

4.3. Asignación de orientación

Para cada keypoint con escala σ_k, se calcula la magnitud m y orientación θ del gradiente en una vecindad de radio $1{,}5\sigma_k$:

$$m(x, y) = \sqrt{(L(x+1, y) - L(x-1, y))^2 + (L(x, y+1) - L(x, y-1))^2} \tag{35}$$

$$\theta(x, y) = \arctan\left(\frac{L(x, y+1) - L(x, y-1)}{L(x+1, y) - L(x-1, y)}\right) \tag{36}$$

Se construye un histograma de orientaciones con 36 bins (cada bin $= 10$), ponderado por $m(x, y) \cdot G(x, y, 1{,}5\sigma_k)$. La orientación dominante θ_{dom} se asigna al keypoint. Si existe un pico secundario $\geq 80\,\%$ del máximo, se crea un keypoint duplicado con esa orientación.

4.4. Descriptor SIFT

El descriptor se calcula en una región de 16×16 píxeles alrededor del keypoint, rotada según θ_{dom} para garantizar invarianza a rotación.

4.4.1. Construcción

La región se divide en una cuadrícula de 4×4 sub-bloques de 4×4 píxeles cada uno. En cada sub-bloque se calcula un histograma de 8 orientaciones de gradiente (relativas a θ_{dom}):

$$h_b(\theta_{\text{rel}}) = \sum_{(x,y)\in B_b} m(x,y) \cdot G(x,y,8) \cdot w_{\text{trilinear}}(x,y,\theta_{\text{rel}}) \tag{37}$$

donde B_b es el b-ésimo sub-bloque, $\theta_{\text{rel}} = \theta(x,y) - \theta_{\text{dom}}$, y $w_{\text{trilinear}}$ realiza interpolación trilineal (en x, y y θ) para evitar efectos de frontera.

El descriptor final es la concatenación de los 16 histogramas de 8 bins:

$$\mathbf{d} = (h_1(1), \ldots, h_1(8),\ h_2(1), \ldots, h_2(8),\ \ldots,\ h_{16}(1), \ldots, h_{16}(8))^\top \in \mathbb{R}^{128} \tag{38}$$

4.4.2. Normalización

Se aplica normalización en dos pasos para invarianza a iluminación:

$$\mathbf{d}' = \frac{\mathbf{d}}{\|\mathbf{d}\|_2}, \qquad \mathbf{d}'' = \frac{\text{mín}(\mathbf{d}', 0{,}2)}{\|\,\text{mín}(\mathbf{d}', 0{,}2)\|_2} \tag{39}$$

El truncamiento a 0,2 reduce la influencia de gradientes dominantes (por ejemplo, por reflejos especulares).

Dimensiones: Por cada imagen: N keypoints, cada uno con posición $(x,y) \in \mathbb{R}^2$, escala $\sigma \in \mathbb{R}^+$, orientación $\theta \in [0, 2\pi)$ y descriptor $\mathbf{d} \in \mathbb{R}^{128}$. Matriz de descriptores: $\mathbf{D} \in \mathbb{R}^{N\times 128}$.

4.5. Matching: distancia L_2 y ratio test de Lowe

4.5.1. Distancia entre descriptores

Para dos descriptores $\mathbf{d}_i \in \mathbb{R}^{128}$ (de la imagen 1) y $\mathbf{d}_j \in \mathbb{R}^{128}$ (de la imagen 2), la distancia es:

$$d(\mathbf{d}_i, \mathbf{d}_j) = \|\mathbf{d}_i - \mathbf{d}_j\|_2 = \sqrt{\sum_{l=1}^{128} (d_i^{(l)} - d_j^{(l)})^2} \tag{40}$$

4.5.2. kNN con $k = 2$

Para cada descriptor $\mathbf{d}_i$ de la imagen 1, se encuentran los dos vecinos más cercanos en la imagen 2:

$$m_i = \arg\min_j\ d(\mathbf{d}_i, \mathbf{d}_j), \qquad n_i = \arg\min_{j\neq m_i}\ d(\mathbf{d}_i, \mathbf{d}_j) \tag{41}$$

Dimensiones: Para N_1 keypoints en la imagen 1 y N_2 en la imagen 2, se computa una matriz de distancias implícita $\mathbf{\Delta} \in \mathbb{R}^{N_1\times N_2}$.

4.5.3. Ratio test de Lowe

Un match $(\mathbf{d}_i, \mathbf{d}_{m_i})$ se acepta si y solo si:

$$\frac{d(\mathbf{d}_i, \mathbf{d}_{m_i})}{d(\mathbf{d}_i, \mathbf{d}_{n_i})} < \tau = 0{,}75 \tag{42}$$

Justificación probabilística: si $\mathbf{d}_i$ tiene un verdadero correspondiente, la distancia al match correcto será significativamente menor que al segundo mejor (que es un distractor aleatorio). Lowe demostró empíricamente que $\tau = 0{,}75$ elimina el $\sim$90 % de los falsos positivos reteniendo >95 % de los verdaderos positivos.

Dimensiones: Salida: conjunto $\mathcal{G} = \{(i, m_i)\}$ de $|\mathcal{G}|$ matches buenos, con $|\mathcal{G}| \geq 8$. Cada match produce un par de puntos correspondientes $(\mathbf{p}_i^{(1)}, \mathbf{p}_{m_i}^{(2)}) \in \mathbb{R}^2 \times \mathbb{R}^2$.

5. Etapas compartidas

A partir de este punto, ambos pipelines operan sobre el mismo tipo de entrada: un conjunto de N pares de puntos correspondientes $\{(\mathbf{x}_i, \mathbf{x}'_i)\}_{i=1}^{N}$ con $\mathbf{x}_i, \mathbf{x}'_i \in \mathbb{R}^2$.

5.1. Estimación de la matriz fundamental

5.1.1. Geometría epipolar

La **matriz fundamental** $\mathbf{F} \in \mathbb{R}^{3\times 3}$ codifica la relación geométrica entre dos vistas no calibradas. Para cualquier par de puntos correspondientes en coordenadas homogéneas:

$$\tilde{\mathbf{x}}'^{\top} \mathbf{F}\, \tilde{\mathbf{x}} = 0 \tag{43}$$

Propiedades de F:

- $\operatorname{rank}(\mathbf{F}) = 2$ (condición de singularidad: $\operatorname{Det}(\mathbf{F}) = 0$).
- $\mathbf{F}$ tiene 7 grados de libertad (9 entradas $-$ 1 por escala $-$ 1 por la restricción $\operatorname{Det} = 0$).
- La línea epipolar de $\mathbf{x}$ en la segunda imagen es $\mathbf{l}' = \mathbf{F}\,\tilde{\mathbf{x}}$.
- Los epipolos satisfacen $\mathbf{F}\,\tilde{\mathbf{e}} = \mathbf{0}$ y $\mathbf{F}^{\top}\tilde{\mathbf{e}}' = \mathbf{0}$.

5.1.2. Relación con la matriz esencial

Si las matrices de calibración $\mathbf{K}$ y $\mathbf{K}'$ fueran conocidas:

$$\mathbf{F} = \mathbf{K}'^{-\top} \mathbf{E}\, \mathbf{K}^{-1} \tag{44}$$

donde $\mathbf{E} = [\mathbf{t}]_{\times}\mathbf{R}$ es la matriz esencial ($\mathbf{R} \in SO(3)$, $\mathbf{t} \in \mathbb{R}^3$). En nuestro caso **no conocemos** $\mathbf{K}$, por lo que trabajamos directamente con $\mathbf{F}$.

5.1.3. Algoritmo de 8 puntos normalizado

Cada correspondencia $(\tilde{\mathbf{x}}_i, \tilde{\mathbf{x}}'_i)$ genera una ecuación lineal en las entradas de $\mathbf{F}$. Sea $\mathbf{f} = \operatorname{vec}(\mathbf{F}) \in \mathbb{R}^9$:

$$\mathbf{a}_i^{\top} \mathbf{f} = 0 \tag{45}$$

donde:

$$\mathbf{a}_i = \begin{pmatrix} x'_i x_i \\ x'_i y_i \\ x'_i \\ y'_i x_i \\ y'_i y_i \\ y'_i \\ x_i \\ y_i \\ 1 \end{pmatrix} \in \mathbb{R}^9 \tag{46}$$

Con $N \geq 8$ correspondencias, el sistema $\mathbf{Af} = \mathbf{0}$ (donde $\mathbf{A} \in \mathbb{R}^{N\times 9}$) se resuelve buscando el vector singular derecho asociado al menor valor singular de $\mathbf{A}$:

$$\mathbf{A} = \mathbf{U}\boldsymbol{\Sigma}\mathbf{V}^\top \implies \mathbf{f} = \mathbf{v}_9 \tag{47}$$

Para mejorar el condicionamiento numérico, se aplica la **normalización de Hartley**: trasladar los puntos para que su centroide sea el origen y escalar para que la distancia media al origen sea $\sqrt{2}$:

$$\mathbf{T} = \begin{pmatrix} s & 0 & -s\bar{x} \\ 0 & s & -s\bar{y} \\ 0 & 0 & 1 \end{pmatrix}, \quad s = \frac{\sqrt{2}}{\frac{1}{N}\sum_i \|\mathbf{x}_i - \bar{\mathbf{x}}\|_2} \tag{48}$$

Tras estimar $\hat{\mathbf{F}}$ con los puntos normalizados, se desnormaliza: $\mathbf{F} = \mathbf{T}'^\top \hat{\mathbf{F}}\,\mathbf{T}$.
Finalmente, se impone la restricción $\operatorname{rank}(\mathbf{F}) = 2$ mediante SVD:

$$\mathbf{F} = \mathbf{U}\,\operatorname{diag}(\sigma_1, \sigma_2, \sigma_3)\,\mathbf{V}^\top \implies \mathbf{F}' = \mathbf{U}\,\operatorname{diag}(\sigma_1, \sigma_2, 0)\,\mathbf{V}^\top \tag{49}$$

Dimensiones: $\mathbf{F} \in \mathbb{R}^{3\times 3}$, $\operatorname{rank}(\mathbf{F}) = 2$, 7 DOF. $\mathbf{A} \in \mathbb{R}^{N\times 9}$.

5.1.4. RANSAC

El algoritmo RANSAC itera:

1. Seleccionar aleatoriamente 8 correspondencias.
2. Estimar $\mathbf{F}$ con el algoritmo de 8 puntos.
3. Contar inliers: un punto $(\mathbf{x}_i, \mathbf{x}'_i)$ es inlier si la distancia punto-a-línea epipolar es menor que $\epsilon = 1{,}0$ píxeles:

$$d(\mathbf{x}'_i,\, \mathbf{F}\tilde{\mathbf{x}}_i) = \frac{|\tilde{\mathbf{x}}'^\top_i \mathbf{F}\,\tilde{\mathbf{x}}_i|}{\sqrt{(\mathbf{F}\tilde{\mathbf{x}}_i)_1^2 + (\mathbf{F}\tilde{\mathbf{x}}_i)_2^2}} < \epsilon \tag{50}$$

El número de iteraciones necesarias para garantizar con probabilidad $p = 0{,}99$ que al menos una muestra esté libre de outliers es:

$$N_{\text{iter}} = \left\lceil \frac{\log(1-p)}{\log(1-w^8)} \right\rceil \tag{51}$$

donde w es la fracción estimada de inliers (actualizada dinámicamente).

Dimensiones: Entrada: N pares $(\mathbf{x}_i, \mathbf{x}'_i)$. Salida: $\mathbf{F} \in \mathbb{R}^{3\times 3}$, máscara de inliers $\mathbf{m} \in \{0,1\}^N$, y subconjuntos filtrados con $N_{\text{in}} = \sum_i m_i$ inliers, $N_{\text{in}} \geq 8$.

5.2. Rectificación estéreo no calibrada

5.2.1. Objetivo

Encontrar dos homografías $\mathbf{H}_1, \mathbf{H}_2 \in \mathbb{R}^{3\times 3}$ tales que las líneas epipolares se mapeen a líneas horizontales. Equivalentemente, que los epipolos se envíen al punto ideal $(1, 0, 0)^\top$ (punto de fuga en el infinito horizontal).

5.2.2. Método de Hartley (1999)

Paso 1: Calcular los epipolos $\mathbf{e}, \mathbf{e}'$ como los vectores nulos de $\mathbf{F}^\top$ y $\mathbf{F}$ respectivamente.

Paso 2: Construir $\mathbf{H}_2$ que envía $\mathbf{e}'$ a $(1, 0, 0)^\top$:

$$\mathbf{H}_2 = \mathbf{G}\,\mathbf{R}\,\mathbf{T} \tag{52}$$

donde $\mathbf{T}$ traslada el centroide de la imagen al origen, $\mathbf{R}$ rota $\mathbf{e}'$ sobre el eje x, y $\mathbf{G}$ lo envía al infinito.

Paso 3: Encontrar $\mathbf{H}_1$ tal que $\mathbf{H}_1\mathbf{A}\mathbf{H}_2^{-1}$ aproxime la identidad, donde $\mathbf{A}$ es la transformación afín que minimiza la distorsión. La condición es que los puntos correspondientes tengan la misma coordenada y tras la rectificación:

$$\min_{\mathbf{H}_1} \sum_i \|\mathbf{H}_1\tilde{\mathbf{x}}_i - \mathbf{H}_2\tilde{\mathbf{x}}'_i\|^2 \tag{53}$$

sujeto a que $\mathbf{H}_1$ preserve la estructura epipolar.

5.2.3. Transformación de las imágenes

Cada imagen se transforma mediante una **transformación proyectiva** (homografía). Para cada píxel destino (x', y') en la imagen rectificada:

$$\begin{pmatrix} wx \\ wy \\ w \end{pmatrix} = \mathbf{H}^{-1} \begin{pmatrix} x' \\ y' \\ 1 \end{pmatrix} \tag{54}$$

y el valor del píxel se obtiene por interpolación bilineal en la posición $(x/w, y/w)$ de la imagen original.

Dimensiones: Entrada: $I_1, I_2 \in \mathbb{R}^{H' \times W'}$, $\mathbf{F} \in \mathbb{R}^{3\times 3}$, puntos inliers. Salida: $I_1^{\text{rect}}, I_2^{\text{rect}} \in \mathbb{R}^{H' \times W'}$ (mismas dimensiones que las originales). Después de la rectificación, para cada correspondencia verdadera $(\mathbf{x}_i, \mathbf{x}'_i)$, se cumple $y_i^{\text{rect}} = y_i'^{\text{rect}}$ (misma fila).

5.3. Mapa de disparidad: StereoSGBM

5.3.1. Definición de disparidad

Para imágenes rectificadas, la disparidad de un píxel (x, y) en la imagen izquierda es:

$$d(x, y) = x_L - x_R \tag{55}$$

donde x_R es la coordenada horizontal del punto correspondiente en la imagen derecha (mismo y por rectificación).

La relación con la profundidad (en un sistema calibrado) es:

$$Z = \frac{f \cdot B}{d} \tag{56}$$

donde f es la distancia focal (píxeles) y B es la línea base (metros). En nuestro caso no calibrado, f y B son desconocidos, así que d es un **proxy relativo** de profundidad: d grande $\Leftrightarrow$ objeto cercano, d pequeño $\Leftrightarrow$ objeto lejano.

5.3.2. Función de costo de matching

El costo de asignar disparidad d al píxel $\mathbf{p} = (x, y)$ se calcula por correlación de bloques (*block matching*) de tamaño $b \times b$ ($b = 5$):

$$C_{\mathrm{BT}}(\mathbf{p}, d) = \sum_{(i,j)\in[-r,r]^2} \left| I_1^{\mathrm{rect}}(x+i, y+j) - I_2^{\mathrm{rect}}(x+i-d, y+j) \right| \tag{57}$$

donde $r = \lfloor b/2 \rfloor = 2$. El pipeline usa el costo de Birchfield-Tomasi que interpola sub-píxel para robustez ante muestreo.

Dimensiones: Volumen de costos: $C \in \mathbb{R}^{H' \times W' \times N_d}$ donde $N_d = 128$ es el número de disparidades (`numDisparities`).

5.3.3. Agregación semi-global

SGBM agrega costos a lo largo de R direcciones (en modo `3WAY`, $R = 3$; en modo completo, $R = 8$ o $R = 16$). Para cada dirección $\mathbf{r}$, se define el costo agregado recursivamente:

$$L_{\mathbf{r}}(\mathbf{p}, d) = C(\mathbf{p}, d) + \min \begin{cases} L_{\mathbf{r}}(\mathbf{p}-\mathbf{r}, d) \\ L_{\mathbf{r}}(\mathbf{p}-\mathbf{r}, d-1) + P_1 \\ L_{\mathbf{r}}(\mathbf{p}-\mathbf{r}, d+1) + P_1 \\ \min_k L_{\mathbf{r}}(\mathbf{p}-\mathbf{r}, k) + P_2 \end{cases} - \min_k L_{\mathbf{r}}(\mathbf{p}-\mathbf{r}, k) \tag{58}$$

donde:

- $P_1 = 8b^2 = 200$: penaliza cambios suaves de disparidad (± 1).
- $P_2 = 32b^2 = 800$: penaliza discontinuidades grandes. Siempre $P_2 > P_1$.
- El último término (resta del mínimo global) evita que los valores crezcan sin límite.

El costo agregado total es la suma sobre todas las direcciones:

$$S(\mathbf{p}, d) = \sum_{\mathbf{r}} L_{\mathbf{r}}(\mathbf{p}, d) \tag{59}$$

La disparidad óptima para cada píxel es:

$$d^*(\mathbf{p}) = \underset{d\in[d_{\min},\, d_{\min}+N_d)}{\arg\min} S(\mathbf{p}, d) \tag{60}$$

con $d_{\min} = 0$.

5.3.4. Refinamiento sub-píxel

La disparidad se refina ajustando una parábola a los tres costos ($S(\mathbf{p}, d^*-1)$, $S(\mathbf{p}, d^*)$, $S(\mathbf{p}, d^*+1)$):

$$\hat{d} = d^* - \frac{S(\mathbf{p}, d^*+1) - S(\mathbf{p}, d^*-1)}{2\left(S(\mathbf{p}, d^*+1) - 2S(\mathbf{p}, d^*) + S(\mathbf{p}, d^*-1)\right)} \tag{61}$$

OpenCV retorna el resultado en formato de **punto fijo** con 4 bits fraccionarios (multiplicado por 16), por lo que se divide entre 16.0 para obtener disparidades reales.

5.3.5. Chequeo de consistencia izquierda-derecha

Se computa un segundo mapa de disparidad usando la imagen derecha como referencia: $d_R(x, y)$. Un píxel se marca como válido solo si:

$$|d_L(x, y) - d_R(x - d_L(x, y), y)| \leq \delta_{\text{máx}} = 1 \text{ píxel} \tag{62}$$

5.3.6. Test de unicidad (`uniquenessRatio`)

Sea $C_{\text{mín}} = S(\mathbf{p}, d^*)$ el costo mínimo y C_{2nd} el segundo mínimo fuera de ± 1 del óptimo. El píxel se invalida si:

$$C_{\text{mín}} > C_{\text{2nd}} \cdot \frac{100 - u}{100} \quad \text{con } u = 10 \tag{63}$$

Es decir, el mínimo debe ser al menos un 10 % mejor que cualquier otro candidato.

5.3.7. Filtrado de *speckle*

Regiones conexas de disparidad se analizan con dos parámetros:

- `speckleWindowSize` $= 100$: regiones con menos de 100 píxeles conectados se eliminan (ruido aislado).
- `speckleRange` $= 32$: dentro de una región conexa, la variación máxima de disparidad permitida es 32 niveles.

Dimensiones: Salida: $d \in \mathbb{R}^{H' \times W'}$. Valores $d > 0$ son disparidades válidas; $d \leq 0$ indica píxeles sin correspondencia. La disparidad vive en el rango $[0, N_d) = [0, 128)$ píxeles.

6. Métricas de evaluación

6.1. Métricas de correspondencia

Cuadro 2: Métricas de correspondencia

Métrica	**Fórmula**	**Rango**
Puntos iniciales	$K = \lvert\mathcal{P}_1\rvert$	$K \leq 3000$ (OF), K varia
tablegray Correspondencias válidas	$N_v = \lvert\{i : s_i = 1\}\rvert$ (OF) ó $\lvert\mathcal{G}\rvert$ (SIFT)	$8 \leq N_v \leq K$
Inliers geométricos	$N_{\text{in}} = \sum_{i=1}^{N_v} m_i$	$8 \leq N_{\text{in}} \leq N_v$

6.2. Métricas de disparidad

6.2.1. Fracción de disparidad válida

$$\rho = \frac{\lvert\{\mathbf{p} : d(\mathbf{p}) > 0\}\rvert}{H' \times W'} \in [0, 1] \tag{64}$$

Un valor ρ alto indica buena cobertura del mapa de profundidad. Valores típicos: $\rho \in [0{,}3, 0{,}8]$ para escenas con textura; $\rho < 0{,}2$ para escenas con grandes regiones uniformes.

6.2.2. Disparidad media

$$\bar{d} = \frac{1}{\lvert\{\mathbf{p} : d(\mathbf{p}) > 0\}\rvert} \sum_{\mathbf{p}:d(\mathbf{p})>0} d(\mathbf{p}) \tag{65}$$

$\bar{d}$ es proporcional a $fB/\bar{Z}$ donde $\bar{Z}$ es la profundidad promedio de la escena. Sin calibración, $\bar{d}$ permite comparación relativa entre pipelines pero no tiene unidades métricas.

7. Visualización

7.1. Normalización del mapa de disparidad

Para visualización, la disparidad se normaliza al rango $[0, 255]$:

$$d_{\text{vis}}(\mathbf{p}) = \begin{cases} \left\lfloor 255 \cdot \dfrac{d(\mathbf{p}) - d_{\text{mín}}}{d_{\text{máx}} - d_{\text{mín}}} \right\rfloor & \text{si } d(\mathbf{p}) > 0 \\ 0 & \text{si } d(\mathbf{p}) \leq 0 \end{cases} \tag{66}$$

donde $d_{\text{mín}} = \text{mín}_{\mathbf{p}:d>0}\, d(\mathbf{p})$ y $d_{\text{máx}} = \text{máx}_{\mathbf{p}:d>0}\, d(\mathbf{p})$.

Dimensiones: Entrada: $d \in \mathbb{R}^{H' \times W'}$. Salida: $d_{\text{vis}} \in \{0, \ldots, 255\}^{H' \times W'}$, visualizado con el colormap "plasma" (azul $\rightarrow$ amarillo $=$ lejos $\rightarrow$ cerca).

7.2. Visualización de correspondencias

Las dos imágenes se concatenan horizontalmente formando un *canvas*:

$$\text{Canvas} \in \mathbb{R}^{\text{máx}(H_1,H_2)\times(W_1+W_2)\times 3} \tag{67}$$

Para cada par de inliers $(\mathbf{x}_i, \mathbf{x}'_i)$ (hasta un máximo de 100 pares seleccionados uniformemente), se dibuja:

- Un círculo de radio 3 px en $\mathbf{x}_i$ sobre la imagen izquierda.
- Un círculo de radio 3 px en $(x'_i + W_1, y'_i)$ sobre la imagen derecha (desplazada horizontalmente).
- Una línea entre ambos círculos con color aleatorio $c \sim \text{Uniform}(\{0, \ldots, 255\}^3)$.

8. Implementación práctica del Pipeline de correspondencias

Esta sección formaliza la implementación computacional de las etapas de matching, filtrado y preparación de datos para la estimación geométrica, siguiendo la misma notación del documento.

8.1. Matching exhaustivo (Brute-Force)

Dado el conjunto de descriptores:

$$\mathbf{D}_1 \in \mathbb{R}^{N_1\times 128}, \qquad \mathbf{D}_2 \in \mathbb{R}^{N_2\times 128} \tag{68}$$

se define la matriz de distancias:

$$\Delta_{ij} = \|\mathbf{d}_i^{(1)} - \mathbf{d}_j^{(2)}\|_2 \tag{69}$$

Para cada descriptor $\mathbf{d}_i^{(1)}$, se seleccionan los dos vecinos más cercanos:

$$m_i = \arg\min_j \Delta_{ij}, \qquad n_i = \arg\min_{j\neq m_i} \Delta_{ij} \tag{70}$$

Dimensiones: Entrada: $\mathbf{D}_1, \mathbf{D}_2$. Salida: pares candidatos $\mathcal{M} = \{(i, m_i, n_i)\}$.

8.2. Filtrado mediante ratio test

Se aplica el criterio:

$$\frac{\Delta_{i,m_i}}{\Delta_{i,n_i}} < \tau, \qquad \tau = 0{,}75 \tag{71}$$

Los matches aceptados forman:

$$\mathcal{G} = \{(i, m_i) : \text{criterio satisfecho}\} \tag{72}$$

Dimensiones: Salida: conjunto $\mathcal{G}$ de correspondencias filtradas.

8.3. Selección espacial uniforme de keypoints

Para evitar concentración espacial, se divide el dominio:

$$\Omega = \bigcup_{r=1}^{R} \bigcup_{c=1}^{C} \Omega_{r,c} \tag{73}$$

Cada celda $\Omega_{r,c}$ contiene un subconjunto de keypoints:

$$\mathcal{P}_{r,c} = \{\mathbf{p}_i \in \Omega_{r,c}\} \tag{74}$$

Se seleccionan los k keypoints con mayor respuesta:

$$\mathcal{P}'_{r,c} = \text{Top-}k(\mathcal{P}_{r,c}) \tag{75}$$

El conjunto final es:

$$\mathcal{P}' = \bigcup_{r,c} \mathcal{P}'_{r,c} \tag{76}$$

Dimensiones: Entrada: $\mathcal{P}$ con N keypoints. Salida: $\mathcal{P}'$ con distribución aproximadamente uniforme.

8.4. Construcción de correspondencias finales

Cada match $(i, m_i) \in \mathcal{G}$ define:

$$\mathbf{x}_i = (x_i, y_i)^\top, \qquad \mathbf{x}'_i = (x'_{m_i}, y'_{m_i})^\top \tag{77}$$

El conjunto final de correspondencias es:

$$\mathcal{C} = \{(\mathbf{x}_i, \mathbf{x}'_i)\}_{i=1}^{N_v} \tag{78}$$

Dimensiones: $\mathcal{C} \subset \mathbb{R}^2 \times \mathbb{R}^2$, con $N_v = |\mathcal{G}|$.

8.5. Filtrado robusto mediante RANSAC

Se estima la matriz fundamental $\mathbf{F}$ usando:

$$\tilde{\mathbf{x}}_i'^\top \mathbf{F} \tilde{\mathbf{x}}_i = 0 \tag{79}$$

y se define la máscara:

$$m_i = \begin{cases} 1 & \text{si } d(\mathbf{x}'_i, \mathbf{F}\mathbf{x}_i) < \epsilon \\ 0 & \text{en otro caso} \end{cases} \tag{80}$$

El subconjunto de inliers es:

$$\mathcal{C}_{\text{in}} = \{(\mathbf{x}_i, \mathbf{x}'_i) : m_i = 1\} \tag{81}$$

Dimensiones: Salida: $\mathbf{F}$ y $N_{\text{in}} = |\mathcal{C}_{\text{in}}| \geq 8$.

8.6. Región válida tras rectificación

Sea Ω el dominio de la imagen rectificada. Se define:

$$\mathcal{V} = \{(x, y) \in \Omega : I_1(x, y) > 0 \wedge I_2(x, y) > 0\} \tag{82}$$

Se restringe el procesamiento a:

$$\Omega' \subseteq \mathcal{V} \tag{83}$$

Dimensiones: Salida: imágenes recortadas I_1', I_2'.

8.7. Cálculo del mapa de disparidad

Se define el volumen de costos:

$$C(\mathbf{p}, d), \quad \mathbf{p} = (x, y) \tag{84}$$

El costo agregado es:

$$S(\mathbf{p}, d) = \sum_{\mathbf{r}} L_{\mathbf{r}}(\mathbf{p}, d) \tag{85}$$

La disparidad óptima es:

$$d^*(\mathbf{p}) = \arg\min_d S(\mathbf{p}, d) \tag{86}$$

OpenCV retorna:

$$d_{\text{raw}} = 16 \cdot d^*(\mathbf{p}) \tag{87}$$

por lo que:

$$d(\mathbf{p}) = \frac{d_{\text{raw}}}{16} \tag{88}$$

Dimensiones: Salida: $d \in \mathbb{R}^{H' \times W'}$ con precisión sub-píxel.